Задача 1

Наивный метод

Для каждой пары мы должны будем посчитать $2d$ возведений в квадрат, затем d вычитаний, и в конце $d-1$ сложений. Всего пар nm.

$$\begin{aligned} \text{Вычитаний:} &\quad nmd \\ \text{Умножений:} &\quad 2nmd \\ \text{Сложений:} &\quad nm(d-1) \\ \text{Всего:} &\quad 4nmd - nm \end{aligned}$$

Оптимизированный метод

Используем формулу:

$$\|x_i - y_j\|^2 = \|x_i\|^2 + \|y_j\|^2 - 2\langle x_i, y_j \rangle$$

На предварительный подсчет норм потратим

$$\begin{aligned} \text{Умножений:} &\quad nd + md \\ \text{Сложений:} &\quad n(d-1) + m(d-1) \end{aligned}$$

На матричное произведение $XY^\top$

На один элемент: d умножений и $d-1$ сложений.

Всего:

$$\begin{aligned} \text{Умножений:} &\quad nmd \\ \text{Сложений:} &\quad nm(d-1) \end{aligned}$$

В итоговой формуле для каждой пары требуется 1 умножение и 2 сложения, значит всего $3mn$ операций.

Итого получаем $nd + md + n(d-1) + m(d-1) + nmd + nm(d-1) + 3nm$ операций

Сравнение

Второй метод использует операции матричного умножения, которые в свою очередь лучше оптимизированы. Также не использует умножения, а также содержит всего $2nmd$ операций вместо $4nmd$ наивного, что может явно сказаться на больших числах.

Задача 2

Медиана:

Для случайной точки X, равномерно распределённой в шаре:

$$\mathbb{P}(\|X\| \le r) = \frac{V_d(r)}{V_d(1)} = r^d, \quad 0 \le r \le 1$$

Пусть $R_{next} = \min\limits_{i=1,\dots,n} \|X_i\|$ — расстояние до ближайшей точки.

Функция распределения:

$$F(r) = \mathbb{P}(R_{next} \le r) = 1 - \mathbb{P}(\text{все} \|X_i\| > r)$$

Вероятность, что одна точка лежит вне шара радиуса r:

$$\mathbb{P}(\|X\| > r) = 1 - r^d$$

Для n независимых точек:

$$\mathbb{P}(\text{все} \|X_i\| > r) = (1 - r^d)^n$$

Следовательно:

$$F(r) = 1 - (1 - r^d)^n$$

Чтобы определить медиану, приравняем $F(r)$ к $\frac{1}{2}$

$$1 - (1 - m^d)^n = \frac{1}{2}$$

$$1 - m^d = 2^{-1/n}$$

$$\boxed{m = \left(1 - 2^{-1/n}\right)^{1/d}}$$

Интерпретация для KNN:

При больших размерностях d медиана будет стремиться к 1 при фиксированных n, что по факту означает, что ближайшими соседями станут практически все точки, а значит применить KNN будет проблематично из-за его неинформативности. При малых размерностях d медиана будет показывать релевантный результат, и метод будет применим. Размерность в общем случае стоит понижать.

Задача 3

Обозначим:

$\xi_z \sim \mathcal{U}[-1, 1]$ — значение признака у объекта z, $\xi_y \sim \mathcal{U}[-1, 1]$ — у объекта y.

Новые расстояния:

$$d_x = \sqrt{r_x^2 + \xi_z^2}, \quad d_y = \sqrt{r_y^2 + (\xi_z - \xi_y)^2}$$

$$r_y^2 + (\xi_z - \xi_y)^2 < r_x^2 + \xi_z^2 \Rightarrow r_y^2 - r_x^2 + (\xi_z - \xi_y)^2 - \xi_z^2 < 0$$

$$r_y^2 - r_x^2 + \xi_z^2 - 2\xi_z\xi_y + \xi_y^2 - \xi_z^2 < 0 \Rightarrow -2\xi_z\xi_y + \xi_y^2 < r_x^2 - r_y^2$$

Обозначим:

$$\delta = r_y^2 - r_x^2 > 0 \Rightarrow p = \mathbb{P}(-2\xi_z\xi_y + \xi_y^2 < -\delta)$$

Так как $\xi_z, \xi_y \sim \mathcal{U}[-1, 1]$, независимы, то:

$$p = \frac{1}{4} \iint\limits_{[-1,1]^2} \mathbb{I}\left(-2\xi_z\xi_y + \xi_y^2 < -\delta\right)\, d\xi_z\, d\xi_y$$

Зафиксируем $\xi_y = t \in [-1, 1]$

$$\xi_z > \frac{\delta + t^2}{2t}, \quad t > 0,$$

$$\xi_z < \frac{\delta + t^2}{2t}, \quad t < 0.$$

Поскольку $\xi_z \sim \mathcal{U}[-1, 1]$, вычислим условную вероятность:

$$P_{\xi_z|\xi_y=t} = \begin{cases} \dfrac{1 - \max\left(-1, \min\left(1, \frac{\delta+t^2}{2t}\right)\right)}{2}, & t > 0, \\ \dfrac{\min\left(1, \max\left(-1, \frac{\delta+t^2}{2t}\right)\right) + 1}{2}, & t < 0. \end{cases}$$

Искомая вероятность равна интегралу по t:

$$p(\delta) = \frac{1}{2}\int_{-1}^{1} P_{\xi_z|\xi_y=t}\, dt = \frac{1}{4}\left[\int_{-1}^{0}\left(\min\left(1, \max\left(-1, \frac{\delta + t^2}{2t}\right)\right) + 1\right) dt + \int_{0}^{1}\left(1 - \max\left(-1, \min\left(1, \frac{\delta}{-}\right.\right.\right.\right.$$

Таким образом, задача сведена к вычислению одномерного интеграла.

Обозначим:

$$g(t) = \frac{\delta + t^2}{2t} = \frac{\delta}{2t} + \frac{t}{2}.$$

$$g(t) = \pm 1 \quad \Rightarrow \quad t^2 \mp 2t + \delta = 0.$$

$$t_- = -1 + \sqrt{1 - \delta}, \quad t_+ = 1 - \sqrt{1 - \delta}, \quad \text{при } \delta \le 1.$$

$$p(\delta) = \frac{1}{4}(I_1 + I_2),$$

где

$$I_1 = \int_{-1}^{t_-} \left(\frac{\delta}{2t} + \frac{t}{2} + 1\right) dt, \quad I_2 = \int_{t_+}^{1} \left(-\frac{\delta}{2t} - \frac{t}{2} + 1\right) dt.$$

Вычисляем:

$$I_1 = \frac{\delta}{2} \ln |t_-| + \frac{1}{4}(t_-^2 - 1) + (t_- + 1),$$

$$I_2 = \frac{\delta}{2} \ln t_+ - \frac{1}{4}(1 - t_+^2) + (1 - t_+).$$

Итоговое выражение:

$$\boxed{p(\delta) = \frac{1}{4}\left[\frac{\delta}{2} \ln |t_-| + \frac{1}{4}(t_-^2 - 1) + (t_- + 1) + \frac{\delta}{2} \ln t_+ - \frac{1}{4}(1 - t_+^2) + (1 - t_+)\right]}$$

где

$$t_- = -1 + \sqrt{1 - \delta}, \quad t_+ = 1 - \sqrt{1 - \delta}.$$

Интерпретация для KNN:

При близких расстояниях добавление любого, даже малозначащего признака может изменить ситуацию и расположение соседей друг относительно друга, что может повлиять на классификацию.

Задача 4

ROC-AUC это площадь под графиком TPR(FPR), который строится поточечно, когда мы меняем TPR(t) и FPR(t) и t пробегает от 0 до 1. TPR отвечает за то что модель угадывает, FPR - за то что нет (В общем случае TPR - условная вероятность того, что score $>$ t - порога, при условии положительного класса, score выдается классификатором). В случае рандомного классификатора график ROC будет прямой с k=1 от 0 до 1, что означает, что площадь под ним будет 1/2.

Задача 5

Используем для ясности формулу

$$\text{AUC} = P(a_+ > a_-) + \tfrac{1}{2}P(a_+ = a_-),$$

где a_+ и a_- — оценки положительных и отрицательных объектов соответственно.

Без ограничения общности можно считать модель корректной, то есть она не выдает инвертированный результат. Тогда AUC хотя бы 0,5 как у случайного классификатора. Покажем, как может произойти падение с 1 до 0,5, оно и будет максимальным. Пусть все $a_+ > 0.5$ и все $a_- > 0.5$. При этом они распределены так, что $P(a_+ > a_-) = 1$. Тогда при использовании нашей функции

$$a'_+ = a'_- = 0.5 \;\Rightarrow\; P(a'_+ > a'_-) = 0, \quad P(a'_+ = a'_-) = 1,$$

и, следовательно, все scores становятся неразличимы как у случайного классификатора.

$$\mathrm{AUC}' = \tfrac{1}{2}.$$

$$\boxed{\Delta\mathrm{AUC}_{\max} = 0.5.}$$

Задача 6

Получим плотности распределения оценок:

$$f(m \mid y = 1) = p(m) = -1.5m^2 + 3m$$

$$f(m \mid y = 0) = 2 - p(m) = 1.5m^2 - 3m + 2$$

$$\mathrm{TPR}(t) = \int_t^1 p(z)dz = \int_t^1 (-1.5z^2 + 3z)dz$$

$$= \left[-0.5z^3 + 1.5z^2\right]_t^1 = 1 - (-0.5t^3 + 1.5t^2)$$

$$\mathrm{TPR}(t) = 1 + 0.5t^3 - 1.5t^2$$

$$\mathrm{FPR}(t) = \int_t^1 (1.5z^2 - 3z + 2)dz$$

$$= \left[0.5z^3 - 1.5z^2 + 2z\right]_t^1 = 1 - (0.5t^3 - 1.5t^2 + 2t)$$

$$\mathrm{FPR}(t) = 1 - 0.5t^3 + 1.5t^2 - 2t$$

$$\mathrm{AUC} = \int_0^1 \mathrm{TPR}(t) \cdot (-\mathrm{FPR}'(t))dt$$

$$\mathrm{FPR}'(t) = -1.5t^2 + 3t - 2 \Rightarrow -\mathrm{FPR}'(t) = 1.5t^2 - 3t + 2$$

$$\mathrm{AUC} = \int_0^1 (1 + 0.5t^3 - 1.5t^2)(1.5t^2 - 3t + 2)dt$$

$$(1 + 0.5t^3 - 1.5t^2)(1.5t^2 - 3t + 2) = 0.75t^5 - 3.75t^4 + 5.5t^3 - 1.5t^2 - 3t + 2$$

$$\int_0^1 = 0.125 - 0.75 + 1.375 - 0.5 - 1.5 + 2 = 0.75$$

$$\boxed{0.75}$$